



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده ریاضی و علوم کامپیوتر

پروژه مباحثی در ریاضیات و کاربردها:
تجزیه QR برای تشخیص دست نوشته

نگارش

آریان فتحی

ارسالان تازیکیه

گروه ۱۰

استاد درس

دکتر فاطمه شاکری

فروردین ۱۴۰۴

چکیده

در این پروژه، به بررسی و پیاده‌سازی روش‌های تجزیه QR برای تشخیص دست نوشته پرداخته شد. با استفاده از ماتریس‌های هاوس هولدر ابتدا تجزیه QR بر روی مجموعه داده‌های Letters EMNIST انجام شد. داده‌های آموزشی به‌عنوان ورودی برای تشکیل ماتریس‌های مربوط به هر کلاس انتخاب شدند و سپس با استفاده از حل مسئله کمترین مربعات، برچسب‌گذاری داده‌های تست انجام شد. در بخش دوم پروژه، تجزیه QR به‌صورت افزایشی- با افزودن داده‌های جدید و استفاده از ماتریس‌های دوران گیونز به‌روزرسانی گردید. نتایج این بخش با نتایج اولیه مقایسه شد و کارایی مدل بررسی شد.

صفحه	فهرست مطالب
أ	چکیده.....
3	فصل اول: تئوری مسئله کمترین مربعات.....
4	فصل دوم : نکات پیاده سازی.....
4	2-1- بخش اول پروژه.....
9	2-3-1- نتایج بخش اول.....
9	2-2- بخش دوم پروژه.....
12	2-3-2- نتایج بخش دوم.....
13	نتیجه گیری.....
13	لینک کد پروژه:.....
14	منابع.....
14 https://eprints.maths.manchester.ac.uk/1192/1/qrupdating_12nov08.pdf

فصل اول: تئوری مسئله کمترین مربعات

در این قسمت سعی می کنیم به طور خلاصه تئوری مسئله کمترین مربعات را بیان کنیم. (دقت کنیم مطالب این بخش از جزوه درس دکتر شاکری الهام گرفته شده و از مطالب آن نیز استفاده می شود).

در حالت کلی مسئله کمترین مربعات به شکل زیر بیان می شود:

مسئله ی کم ترین مربعات:

فرض کنید $A \in \mathbb{R}^{m \times n}$ ($m > n$) و $b \in \mathbb{R}^{m \times 1}$. می خواهیم X ای را بیابیم که $\|b - AX\|_2$ را مینیمم کند.

$$\min_X \|b - AX\|_2$$

در واقع هدف ما حل دستگاهی به شکل $AX = b$ است که A و b در بالا تعریف شده اند. اما می دانیم که الزاما این دستگاه جواب ندارد. در واقع یکی از تعبیرهایی که برای جواب داشتن این دستگاه استفاده می شود، این است که بتوان بردار b را به صورت ترکیبی خطی از ستون های ماتریس A نوشت. حال اگر چنین نباشد، هدف ما یافتن برداری مانند X است به شکلی که بردار AX کمترین فاصله را تا بردار b داشته باشد. در این حالت یافتن برداری مانند X معادل است با جواب معادله نرمال زیر:

$$A^T b = A^T A X$$

که می دانیم این معادله حتما جواب دارد (ممکن است الزاما یکتا نباشد)

اما حل این دستگاه برای حل مسئله کمترین مربعات دارای مشکلاتی مثل از دست رفتن اطلاعات و بدو ضعیف تر شدن مسئله نسبت به مسئله اولیه می باشد. از این رو تلاش می کنیم از ماتریس A به

ماتریسی- مانند B برسیم به طوری که فضای ستونی آنها یکسان باشد و ماتریس ضرایب مسئله نرمال نیز خوش حالت تر شود به عبارتی $B^T B = I$. حال به حل این مسئله و جستجو برای بردار مطلوب در این فضا بپردازیم. یکی از کاربرد های مسئله کمترین مربعات در تشخیص اعداد دست نوشته است که در این پروژه به آن پرداخته شده است.

فصل دوم : نکات پیاده سازی

2-1- بخش اول پروژه

در این بخش ابتدا درباره نحوه خواندن دیتا صحبت می کنیم. همان طور که می دانیم از دیتاست Emnist استفاده می کنیم. در تکه کد زیر دیتاست از Kaggle دانلود می شود و مسیر آن را ذخیره می کنیم:

```
[ ] path = kagglehub.dataset_download("crawford/emnist")  
print("Path to dataset files:", path)
```

همچنین در تکه کد های زیر، دیتافریم را از فایل داندود شده مربوطه می خوانیم و ستون های آن را با توجه به خود دیتاست تشکیل می دهیم:

```
[ ] columns = ["label"] + [f"pixel_val_{i}" for i in range(1, 785)]

[ ] df_letters_train = pd.read_csv(f"{path}/emnist-letters-train.csv", header=None)
df_letters_train.columns = columns
```

در خروجی زیر، می‌توانیم به ۵ داده (دست نوشته) اول دیتاست نگاهی بیندازیم:

[illegible]

در بخش بعدی، دیتاست را نرمالایز می کنیم:

```
# Normalizing dataset leads to better results
scaler = StandardScaler()
df_letters_train.iloc[:, 1:] = scaler.fit_transform(df_letters_train.iloc[:, 1:])
```

با نرمالسازی دیتاست، چون مقادیر تمام پیکسل ها بین ۰ و ۱ است، در نتیجه در فرایند تشکیل مجموعه آموزشی و یادگیری از آن، فرایند robust تر می شود و تاثیر پیکسل های خیلی بزرگ یا خیلی کوچک دیگر زیاد نیست. از طرفی فرایند یادگیری نیز سریع تر می شود چون محاسبات پیچیدگی کمتری خواهند داشت.

در این بخش ابتدا از هر کلاس اعداد، ۲۰۰ نمونه اولیه را به عنوان داده های آموزشی در نظر می گیریم و ماتریس آموزشی متناظر با هر کلاس را تشکیل می دهیم. سپس ۲۰ داده دیگر از هر کلاس را به عنوان ستون به ماتریس تست اضافه می کنیم و ماتریس تست حاصل از کلاس ها را می سازیم:

```
# Creating train and test matrices from letter dataset

def creating_train_and_test_matrices(train_matrices, test_matrices):
    for label in range(1, 27):
        class_samples = df_letters_train[df_letters_train['label'] == label]

        selected_train_samples = class_samples.iloc[:200, 1:].values
        selected_test_samples = class_samples.iloc[200:220, 1:].values

        train_matrices[label] = selected_train_samples.T
        test_matrices.append(selected_test_samples.T)

    test_matrices = np.concatenate(test_matrices, axis=1)

    class_1_matrix_train = train_matrices[1]

    print("Shape of class 1 (A) train matrix:", class_1_matrix_train.shape)
    print("Type of class 1 train matrix:", type(class_1_matrix_train))
    print("Shape of concatenated test matrices:", test_matrices.shape)

    return train_matrices, test_matrices
```

نکته ای که باید به آن توجه کنیم این است که داده های ما (بردار شامل مقادیر پیکسل ها) باید به عنوان بردارهای ستونی در ماتریس ها ظاهر شوند نه سطرها. از این رو از عملیات ترانهاده استفاده می کنیم.

در ادامه از هر کلاس ۲۰ نمونه در نظر می گیریم و آرایه با ۵۲۰ عنصر زیر را می سازیم:

```
# Global Variables
```

```
true_labels = np.repeat(np.arange(1, 27), 20)
```

در تکه کد زیر هم به روش تجزیه QR با استفاده از ماتریس های هاوس هولدر می پردازیم. به طور خلاصه هم می دانیم نحوه صفر کردن عناصر ماتریس ورودی، ساختن ماتریس بالامثلی R، همچنین ماتریس متعامد Q که از ضرب ماتریس های متعامدی به دست می آید که وارون ماتریس های هاوس هولدر هستند که از قضا آن ها هم متعامدند:

```
def qr_decomposition_with_householder(A):  
    [m, n] = A.shape  
    R = A.copy()  
    Q = np.identity(m)  
  
    for i in range(min(m, n)):  
        x_i = R[i:, i]  
        s = np.sign(x_i[0]) if x_i[0] != 0 else 1  
        normx = np.linalg.norm(x_i)  
        e1 = np.zeros_like(x_i)  
        e1[0] = 1  
        v_i = x_i + s * normx * e1  
        v_i = v_i / np.linalg.norm(v_i) # Normalize the Householder vector  
  
        H_i = np.identity(m)  
        H_i[i:, i:] -= 2 * np.outer(v_i, v_i)  
  
        R = np.dot(H_i, R)  
        Q = np.dot(Q, H_i.T)  
  
    return Q, R
```

در ادامه هم چک می کنیم که آیا ماتریس های R و Q بدست آمده، خاصیت های بالامثلی و تعامد را دارند:

```
def is_upper_triangular(R):  
    return np.allclose(R, np.triu(R))  
  
def is_orthogonal(Q):  
    identity = np.eye(Q.shape[0])  
    QTQ = np.dot(Q.T, Q)  
    return np.allclose(QTQ, identity)
```

در تابع بعدی ماتریس های Q و R ای که از تجزیه هر یک از ماتریس های آموزشی کلاس ها به دست می آیند را محاسبه می کنیم و ذخیره می کنیم:

```
def qr_decomposition_of_all_matrices(train_matrices, Q, R):
    for i in tqdm(range(1, len(train_matrices.keys()) + 1), desc="Generating Q and R matrices for all classes of training matrices"):
        Q_i, R_i = qr_decomposition_with_householder(train_matrices[i])
        Q.append(Q_i)
        R.append(R_i)
        if not is_orthogonal(Q_i):
            print(f"Warning: Q{i} is not Orthogonal")
            print("-" * 30)
        if not is_upper_triangular(R_i):
            print(f"Warning: Q{i} is not Upper Triangle")
            print("-" * 30)
    return Q, R
```

در تکه کد زیر هم با استفاده از کمترین مربعات، برچسب نمونه های تست ماتریس تست را مشخص می کنیم:

```
def predict_labels_using_least_square(test_matrices, Q, R):
    m, n = test_matrices.shape
    predicted_labels = np.zeros(n, dtype=int)
    for i in tqdm(range(n), desc="Predicting Labels"):
        min_score = float('inf')
        for j in range(26):
            # Solve the least squares problem using QR decomposition
            y = np.matmul(Q[j].T, test_matrices[:, i])
            x, residuals, rank, s = np.linalg.lstsq(R[j], y, rcond=1e-5)
            score = np.linalg.norm(np.matmul(R[j], x) - y, 2)
            if score < min_score:
                min_score = score
                predicted_labels[i] = j + 1
    return predicted_labels
```

به طور خلاصه برای هر نمونه آن را به فضای کلاس ها تصویر می کنیم. (با استفاده از ماتریس Q دست آمده از تجزیه QR ماتریس آن کلاس)

حل معادله کمترین مربعات: با استفاده از ماتریس R بهترین برآورد برای برچسب کلاس پیدا می شود.

محاسبه خطا: خطایی محاسبه می شود که نشان دهنده ی چقدر بردار بدست آمده به بردار واقعی نزدیک است. خطای کمتر به معنای تطابق بهتر است.

انتخاب برچسب بهتر: اگر خطا برای کلاسی از خطای کلاس های قبلی کمتر شد، برچسب کلاس مربوطه به عنوان پیش بینی برای آن نمونه انتخاب می شود.

در تکه کد زیر هم به طور خلاصه دقت بدست آمده در پیش بینی برچسب داده های مربوط به هر کلاس و همچنین دقت کلی (نسبت پیش بینی ها درست به کل نمونه های تست) را بدست می آوریم:


```
def calculate_accuracy(predicted_labels, true_labels, num_classes=26, samples_per_class=20):
    correct_per_class = np.zeros(num_classes, dtype=int)
    total_per_class = np.zeros(num_classes, dtype=int)

    for i, label in enumerate(predicted_labels):
        true_label = true_labels[i] # Get the corresponding true label
        class_index = true_label - 1 # Assuming labels are 1 to 26

        total_per_class[class_index] += 1 # Count the sample for this class
        if label == true_label:
            correct_per_class[class_index] += 1 # Count correct prediction

    accuracy_per_class = correct_per_class / total_per_class

    overall_accuracy = np.sum(correct_per_class) / np.sum(total_per_class)

    print("Accuracy per class:")
    for class_id in range(num_classes):
        print(f"Class {class_id + 1}: {accuracy_per_class[class_id] * 100:.2f}%")

    print(f"\nOverall Accuracy: {overall_accuracy * 100:.2f}%")
    return accuracy_per_class, overall_accuracy
```

در ادامه هم پایپ لاین مربوط به این قسمت را تشکیل می دهیم و آن را اجرا می کنیم. در ادامه می توانیم نتایج و دقت های بدست آمده از این روش را با هم مشاهده کنیم:

```
def pipeline_without Updating():
    train_matrices, test_matrices = creating_train_and_test_matrices({}, [])
    Q, R = qr_decomposition_of_all_matrices(train_matrices, [], [])
    predicted_labels = predict_labels_using_least_square(test_matrices, Q, R)
    accuracy_per_class, overall_accuracy = calculate_accuracy(predicted_labels, true_labels)
    return train_matrices, test_matrices, Q, R
```

2-3-1- نتایج بخش اول

```
Shape of class 1 (A) train matrix: (784, 200)
Type of class 1 train matrix: <class 'numpy.ndarray'>
Shape of concatenated test matrices: (784, 520)
100%|██████████| 26/26 [04:55<00:00, 11.36s/it]
Predicting Labels: 100%|██████████| 520/520 [05:55<00:00, 1.46it/s]Accuracy per class:
Class 1: 70.00%
Class 2: 60.00%
Class 3: 40.00%
Class 4: 60.00%
Class 5: 70.00%
Class 6: 60.00%
Class 7: 5.00%
Class 8: 45.00%
Class 9: 90.00%
Class 10: 60.00%
Class 11: 60.00%
Class 12: 40.00%
Class 13: 60.00%
Class 14: 65.00%
Class 15: 100.00%
Class 16: 75.00%
Class 17: 60.00%
Class 18: 75.00%
Class 19: 60.00%
Class 20: 70.00%
Class 21: 60.00%
Class 22: 70.00%
Class 23: 75.00%
Class 24: 70.00%
Class 25: 60.00%
Class 26: 75.00%

Overall Accuracy: 62.88%
```

2-2- بخش دوم پروژه

در این بخش تجزیه QR را به صورت افزایشی—و با استفاده از ماتریس ها دوران گیونز انجام می دهیم. به طور خلاصه در تکه کد زیر پارامترهای سینوس و کسینوس ماتریس های دوران گیونز را با توجه به عنصری از بردار که از آنجا به پایین را می خواهیم صفر کنیم و عنصر- بالایی آن در بردار بدست می آوریم. در صورت مشخص شدن این پارامترها، بقیه عناصر ماتریس های دوران مشخص هستند:

```
def givens_rotation(a, b):
    # Computes Givens rotation parameters c, s based on Algorithm 1.1.
    if b == 0.0:
        c = 1.0
        s = 0.0
    else:
        if abs(b) >= abs(a):
            t = -a / b
            s_denom = np.sqrt(1.0 + t**2)
            s = 1.0 / s_denom
            c = s * t
        else:
            t = -b / a
            c_denom = np.sqrt(1.0 + t**2)
            c = 1.0 / c_denom
            s = c * t
    return c, s
```

در تکه کد زیر، با توجه به الگوریتم 2.19 در فایل ضمیمه پروژه با نام Updating the QR factorization and the least squares problem متعلق به دانشگاه منچستر، داریم:

تابع `qr_update_append_col` برای به‌روزرسانی تجزیه QR یک ماتریس پس از افزودن یک ستون جدید u طراحی شده است. ورودی‌های این تابع شامل ماتریس متعامد Q ، ماتریس بالا مثلثی R و بردار ستونی جدید u است. ابتدا، ستون جدید u با استفاده از ماتریس Q به فضای جدید تصویر می‌شود. سپس، این بردار ستونی به ماتریس R افزوده می‌شود و یک ماتریس جدید به نام $R_{\text{augmented}}$ ایجاد می‌کند.

سپس با استفاده از دوران‌های گیونز، عناصر زیر قطر اصلی در ستون جدید صفر می‌شوند. این کار با محاسبه پارامترهای کسینوس و سینوس که در بالا توضیح دادیم انجام می‌شود. دوران معکوس نیز به ماتریس Q اعمال می‌شود تا متعامد بودن آن حفظ شود. در نهایت، تابع ماتریس‌های به‌روزرسانی شده Q و R را برمی‌گرداند.

```

# Implemented algorithm 2.19 from the paper
def qr_update_append_col(Q, R, u):
    """
    Updates Q and R after appending column u to the original matrix A.
    Assumes A = QR, where Q is m x m (orthogonal) and R is m x n (upper trapezoidal).
    u is a new column of size m x 1.
    Returns updated Q_new (m x m) and R_new (m x (n+1)).
    Uses the c, s from the givens_rotation function implementing Algorithm 1.1.
    """
    m, n = R.shape
    m_q, n_q = Q.shape

    u_transformed = Q @ u

    # Augment R with the transformed column
    R_augmented = np.hstack((R, u_transformed.reshape(-1, 1)))

    # Apply Givens rotations to zero out elements below the diagonal
    # in the newly added last column (column index n)
    for i in range(m - 1, n, -1):
        # Target element to zero: R_augmented[i, n]
        # Pivot element: R_augmented[i-1, n]
        a = R_augmented[i - 1, n]
        b = R_augmented[i, n]

        if b != 0.0: # Only need to rotate if the element is non-zero
            # Get Givens parameters from the new function
            c, s = givens_rotation(a, b)

            # Givens Matrix
            G = np.array([[c, -s], [s, c]])

            # Apply rotation G to the relevant rows (i-1 and i) of R_augmented
            R_augmented[i - 1:i + 1, :] = G @ R_augmented[i - 1:i + 1, :]

            # Apply the transpose rotation G.T to the corresponding columns (i-1 and i) of Q
            # Q_new = Q_old @ G.T ensures Q_new remains orthogonal
            Q[:, i - 1:i + 1] = Q[:, i - 1:i + 1] @ G.T

    R_new = R_augmented
    Q_new = Q

    return Q_new, R_new

```

qr_decomposition Updating of all matrices برای به روزرسانی تجزیه QR برای هر کلاس از داده‌های آموزشی طراحی شده است. این تابع به‌طور خاص برای افزودن ۲۰ نمونه جدید به هر کلاس از داده‌ها استفاده می‌شود.

ورودی‌های تابع شامل ماتریس‌های Q و R، مجموعه داده‌های آموزشی، اندازه اولیه آموزش `initial_train_size` و تعداد نمونه‌هایی که باید اضافه شوند هستند.

سپس، با استفاده از یک حلقه، به‌روزرسانی برای هر یک از کلاس‌های ۱ تا ۲۶ انجام می‌شود. در هر تکرار، اندیس کلاس به‌دست می‌آید و نمونه‌های مربوط به آن کلاس از مجموعه داده استخراج می‌شود. اندیس‌های شروع و پایان برای انتخاب نمونه‌های جدید تعیین می‌شوند.

سپس، مقادیر پیکسل‌های نمونه‌های جدید به‌دست می‌آید (ماتریس شامل داده‌های جدید) و برای هر نمونه جدید، ستونی به نام `new_col_u` ساخته می‌شود. این ستون به‌عنوان ورودی به تابع `qr_update_append_col` ارسال می‌شود تا Q و R به‌روزرسانی شوند. بدین ترتیب ماتریس‌های Q و R مربوط به هر کلاس با اضافه شدن داده‌های جدید به هر کلاس به‌روزرسانی می‌شوند.

پس از به‌روزرسانی، دو بررسی انجام می‌شود: اول اینکه آیا Q متعامد باقی مانده است یا خیر و دوم اینکه آیا R همچنان بالا مثلثی است یا خیر.

در نهایت، تابع ماتریس‌های به‌روزرسانی شده Q و R را برمی‌گرداند.

در تکه کد زیر پایپ لاین این روش و نتایج حاصله از اضافه شدن ۲۰ داده جدید به هر کلاس را می‌توانیم مشاهده کنیم:

```
[ ] def pipeline_without Updating():
    train_matrices, test_matrices = creating_train_and_test_matrices({}, [])
    Q, R = qr_decomposition_of_all_matrices(train_matrices, [], [])
    predicted_labels = predict_labels_using_least_square(test_matrices, Q, R)
    accuracy_per_class, overall_accuracy = calculate_accuracy(predicted_labels, true_labels)
    return train_matrices, test_matrices, Q, R
```

2-3-2- نتایج بخش دوم

```
100%|██████████| 26/26 [00:40<00:00, 1.58s/it]
Predicting Labels: 100%|██████████| 520/520 [06:34<00:00, 1.32it/s]Accuracy per class:
Class 1: 70.00%
Class 2: 60.00%
Class 3: 40.00%
Class 4: 60.00%
Class 5: 70.00%
Class 6: 55.00%
Class 7: 5.00%
Class 8: 45.00%
Class 9: 90.00%
Class 10: 60.00%
Class 11: 60.00%
Class 12: 45.00%
Class 13: 60.00%
Class 14: 60.00%
Class 15: 100.00%
Class 16: 75.00%
Class 17: 60.00%
Class 18: 75.00%
Class 19: 65.00%
Class 20: 70.00%
Class 21: 60.00%
Class 22: 75.00%
Class 23: 75.00%
Class 24: 70.00%
Class 25: 60.00%
Class 26: 80.00%

Overall Accuracy: 63.27%
```

همان طور که مشاهده می‌کنیم با اینکه داده بیش تری برای آموزش داشتیم، دقت کلی افت کرده است. در کلاس‌هایی که دقت تغییر کرده است (مثل کلاس ۲۶، کلاس ۱۹ و ...) کاهش دقت را داشته ایم. این مسئله می‌تواند دلایل متفاوتی داشته باشد. مثلاً داده‌های جدید دارای نویز باشند

و فضای ستونی حاصل از ماتریس آموزش و معادلا فضای ستونی ماتریس متعامد Q حاصل از تجزیه آن، به خوبی فضای مربوطه به آن کلاس را نسازد و فضای ستونی خیلی تغییر کند با اضافه کردن داده های جدید. یا ممکن است داده های پرت باشند و خیلی فضا را تغییر دهند.

نتیجه گیری

در این پروژه ما از تجزیه QR برای حل مسئله کمترین مربعات استفاده کردیم و دیدیم که این روش نسبتاً ساده از لحاظ پیاده سازی می تواند دقت نسبتاً خوبی روی دیتاست Emnist به ما بدهد. در ادامه و با پیاده سازی بخش دوم، متوجه شدیم که داشتن داده بیش تر و اضافه کردن داده به دیتاست اولیه الزاماً موجب بهبود عملکرد مدل پیش بینی کننده نمی شود. عواملی مانند نویز در داده های جدید، پرت بودن نسبت فضای ستونی ماتریس آموزش اولیه و ... می توانند موجب تغییر زیاد فضای جدید و در نتیجه تغییر در دقت کلی مدل شود (فضای ستونی ماتریس اولیه که تغییر کند، فضای ستونی ماتریس متعامد Q حاصله از تجزیه QR نیز تغییر می کند چون فضای ستونی آنها طبق قضیه ای در جزوه یکسان است). کما اینکه در این پروژه با کاهش دقت مواجه بودیم. این مورد در دیگر الگوریتم های یادگیری ماشین نیز مشاهده می شود و بیش تر کردن داده آموزشی اگر از کیفیت و کمیت لادم برخوردار نباشد، می تواند موجب اشتباه در فرایند یادگیری شود و دقت مدل ما، کاهش پیدا کند.

لینک کد پروژه

https://colab.research.google.com/drive/1NbJfiCuuKaap_2SX8VaHCsbFFGHdKPwY?scrollTo=dX5XYj29hkas

منابع

https://eprints.maths.manchester.ac.uk/1192/1/grupdating_12nov08.pdf

جزوه درس کاربرد های جبر خطی در علم داده دکتر فاطمه شاکری

https://iasbs.ac.ir/~narimani/rsrc/cdm/Matrix_methods_in_data_mining.pdf